加推数据特征工程实战

> 在机器学习或使用之前对数据进行清洗、标准化、降维等，是技术人员必不可少的技能💢

从需求说起

- 系统用户有大量的频度指标，我们希望对用户画像进行分类和打标。（分类与聚类）🙂
- 产品运营有大量的指标需要分析，产生有价值的报表。（聚类）
- 销售膜拜、电话、大客，还是团队作战，哪项行为更符合我们的产品？（分类）🙂

数据科学的第一步：特征工程

- 特征工程，说白了就是对待分析的数据进行预处理、特征选择、降维等操作。💢

基础知识（主要是矩阵操作）

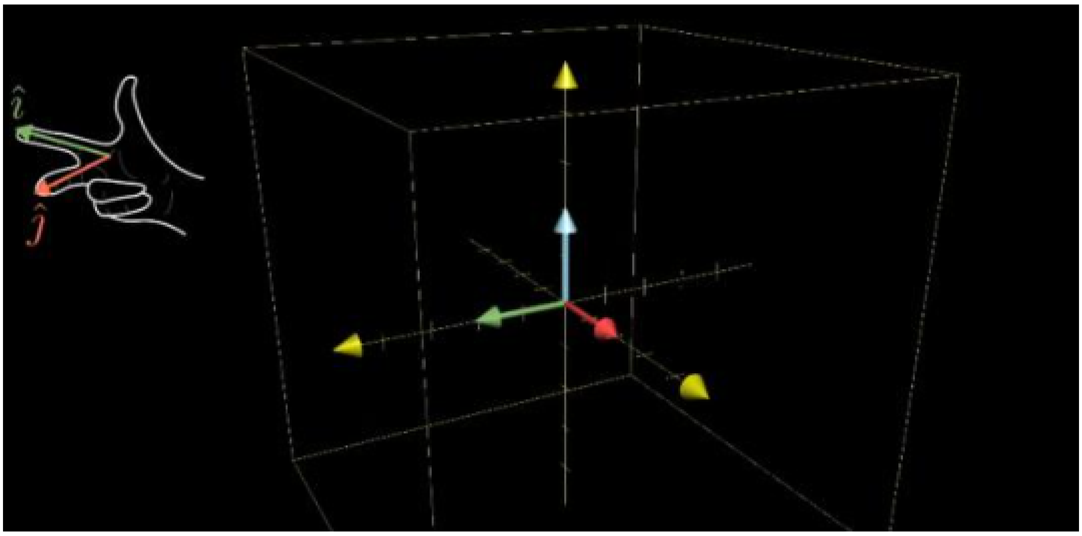

> 首先随便用JS写一套 矩阵操作的函数集（编写难度很低，看着公式，中级程序猿可以轻易完成300行代码左右）💢
>
> 线代基础网上很多，我们用到的也就是这些基础的组合，上一篇卷积操作会相对难一些。

- 复制矩阵（浅copy）
- 矩阵转置（下面会用到）

```
matrix.transpose = function (arr) {
  let result = new Array(arr[0].length)
  for (let i = 0; i < arr[0].length; i++) {
    result[i] = new Array(arr.length)
    for (let j = 0; j < arr.length; j++) {
      result[i][j] = arr[j][i]
    }
  }
  return result
}
```

- 加法
- 减法
- 比例
- 叉乘
- 点乘
- 矩阵行列式（det）
- 全 0 矩阵（zero）
- 单位矩阵（I）
- 高斯约旦消元法
- 求逆矩阵（inv）

> 封装到Sky核心库的 **$.math.mat** 下
>
> 有了这几个基础函数我们就可以完（wei）成（suo）功（yu）能（wei）
>
> 矩阵操作就是线性转换，大部分的线性变化都会改变向量的方向

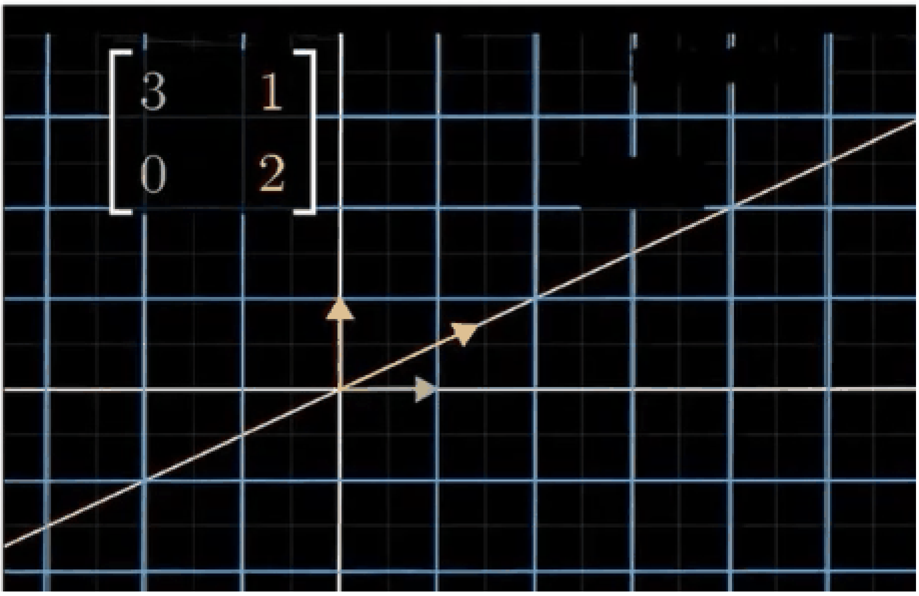

到底有哪些有用的预处理（干货）

无量纲化

> 无量纲化使不同规格的数据转换到同一规格。比如把数据缩放到[0,1]区间等

1、标准化（z-score）

$$X' = \frac{x - \text{mean}}{\sigma}$$

每个数据减去此维度（列）的平均值（mean）除以此维度的标准差或样本标准差（注意标准差和样本标准差的区别）😶

2、区间缩放（归一化）

$$x' = \frac{x - Min}{\text{Max} - Min}$$

每个数据减去此维度（列）的最小值（min）除以他们的极差（range:max-min）好像很简单，常用的处理方式😄

就这2个常用的，其他方法不多说，上JS代码💢

```
let oriArr = [[1,3],[2,4],[3,5]] //3行数据2个维度 这个很重要！！ 对应矩阵的行列
let arr = $.math.mat.transpose(oriArr) // 使用矩阵转置后 [[1,2,3],[3,4,5]]
function zScoreNorm (a) {
  return a.map(x => {
    let mean = $M.mean(x)
    let std = $M.stddev(x)
    x = x.map(it => (it - mean) / std)
    return x
  })
}
function minMaxNorm (a) {
  return a.map(x => {
    let max = $M.max(x)
    let min = $M.min(x)
    x = x.map(it => (it - min) / (max - min))
    return x
  })
}
```

缺失值计算

- 一般出现null 或 NaN的值，用此维度（列）的mean值填充，当然还可以按最近的填充，直接删除，拟合填入或者人工填入特定值
- 数据量大的时候，可以直接删除😄

降维

> 主成分分析法（PCA）我们详细说一下这个，是最常用的降维方式
>
> 举个例子就是你在3维世界，但你的影子是在平面上的，影子表征了你的特征，但它不是你😶

- 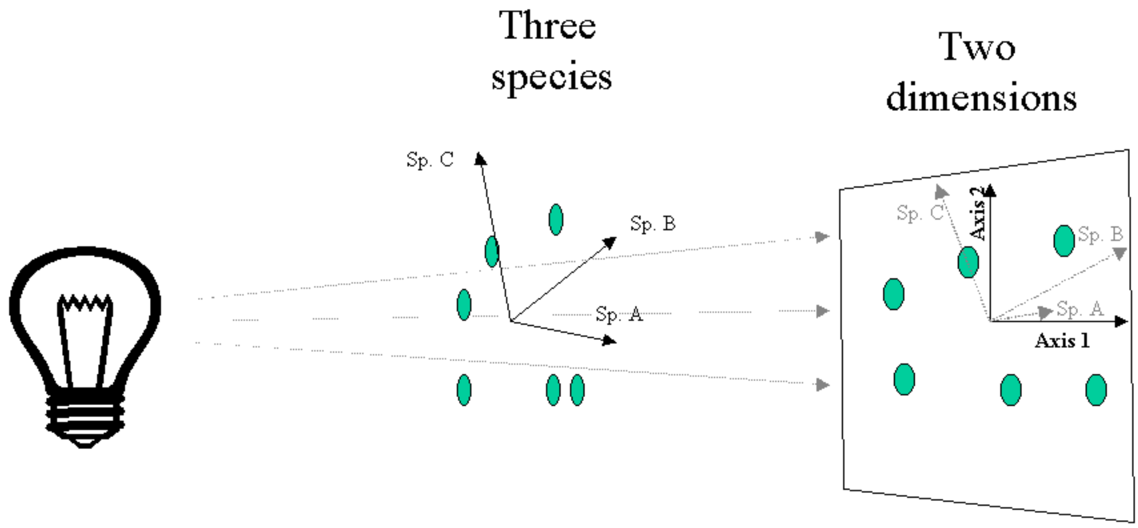

PCA算法的执行步骤

- 将数据每个维度，中心化（零化均值），注意这里不是缩放，只是 减去mean
  - 每个数据减去他所在列的平均值，上代码
  - ```
    function meanStandard (a) {
      let meanArr = []
      // 均值中心化
      let arr = $M.mat.transpose(a).map(x => { // 注意这里是原数据矩阵的话，需要转置
        let mean = $M.mean(x)
        meanArr.push(mean)
        x = x.map(it => it - mean) // 每列减去本列的mean值
        return x
      })
      return { meanMat: $M.mat.transpose(arr), meanArr: meanArr }
    }
    ```
- 将原始数据转置后，求出协方差，并形成矩阵
  - 方差计算应该人人都会了🙂
  - $\operatorname{cov}(X,Y)=\frac{\sum_{i=1}^{n}(X_i-\bar{X})(Y_i-\bar{Y})}{n-1}$ **样本**协方差计算公式，方差是特殊的协方差X=Y
  - 如果数据有3个维度{x,y,z}
  - 协方差矩阵就是$C=\begin{pmatrix}\operatorname{cov}(x,x) & \operatorname{cov}(x,y) & \operatorname{cov}(x,z)\\ \operatorname{cov}(y,x) & \operatorname{cov}(y,y) & \operatorname{cov}(y,z)\\ \operatorname{cov}(z,x) & \operatorname{cov}(z,y) & \operatorname{cov}(z,z)\end{pmatrix}$
  - 对于n维
  - $C_{n\times n}=(c_{i,j},c_{i,j}=\operatorname{cov}(\mathrm{Dim}_i,Dim_j))$
  - 把公式写成代码👌
    ```

- ```
  const cov = function (mat) {
    let len = mat.length
    let a = []
    for (let i = 0; i < len; i++) {
      a[i] = []
      for (let j = 0; j < len; j++) {
        a[i][j] = $M.covarianceCorrect(mat[i], mat[j]) / len //可以不除len,最后的数据只是影响缩放
      }
    }
    return a
  }
  ```
-

- 将协方差矩阵进行SVD奇异值分解（方阵M*M可以特征值分解，非方阵一般使用奇异值分解
- SVD是一个O(N^3)的算法，Google有并行解决方案，最近都喜欢用GPU算，自行扩展阅读
  - $A = U\Sigma V^T$ 注意这里西格玛 不是累加算子😶
  - 含义如下:
  - 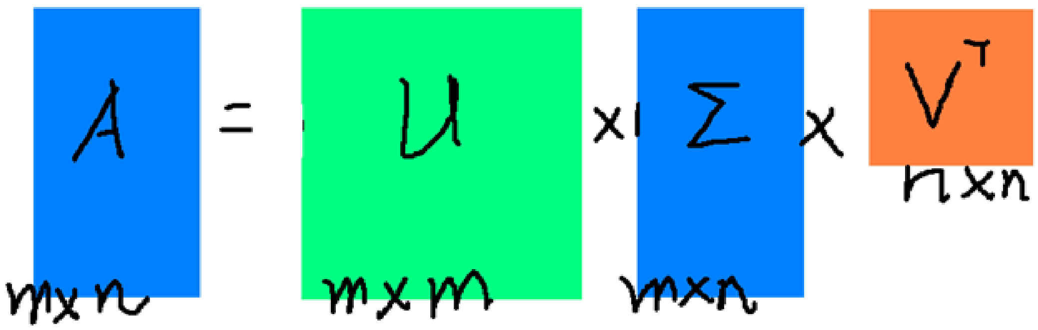

  - 图1

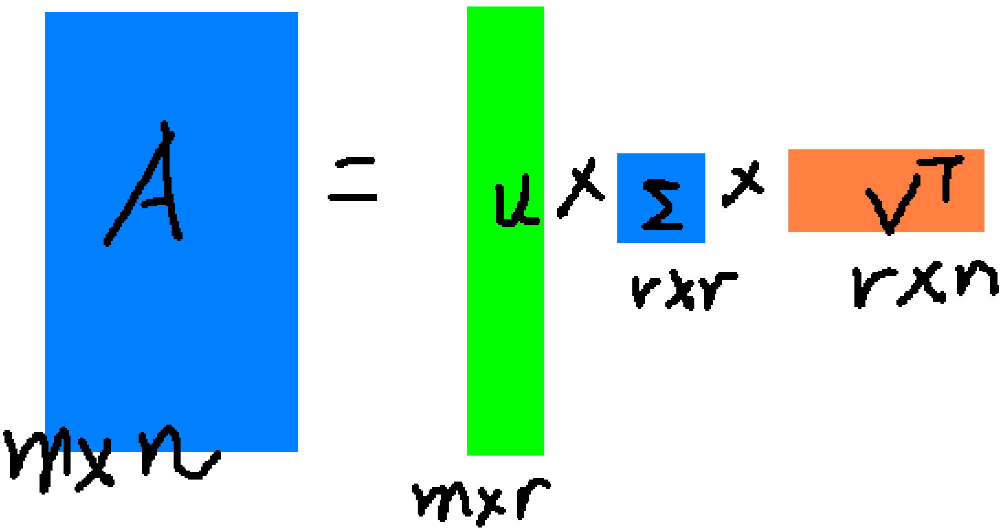

图2

  - 上面第1个图，代表矩阵A，先旋转再拉伸，最后投影到V基
  - 上第2图R<=N，如果R被缩小，最后的数据就从 MxN => MxR，也就是被降维了
  - U代表一个 正交矩阵，也就是 每个维度都是垂直的😶，理解一下4个维度互相垂直的情景😥
- 用findMainFactor函数，找到最佳阀值点
  - R是一个对角矩阵，对角线上的值成为奇异值（方阵的话叫特征值）
  - 也就是一串数值，没啥神奇
  ```

> - 如果我们的阀值threshold=0.95，就是需要取多少个R，让R/总奇异值和>=threshold
> - 在下面鸢尾花的例子中，取2列就可以达到97%，意味着2维新数值维度，可以很好解释原4维
> - 上代码
> - ```
>   function findMainFactor (a, percent = 0.95) {
>     let sum = $M.sum(a)
>     let cumulat = 0
>     for (let i = 0; i < a.length; i++) {
>       cumulat += a[i]
>       if (cumulat / sum >= percent) {
>         return i + 1
>       }
>     }
>     return a.length
>   }
>   ```
> - 非常简单😄

- 按阀值的维度取左奇异矩阵的，相应降维后维度

  > 降维R后，相同降维左奇异矩阵U，别急下面有代码😄

- 将中心化后的数据和上面的降维后的维度，矩阵相乘

  > 拿出上面的矩阵乘操作

- 得出相应压缩过的新矩阵（降维矩阵）

> 于是整个过程就是一个无监督学习过程💥

说了这么多公（fei）式（hua）具体怎么做（干货）？

- 全网搜索后，发现PCA算法**几乎**都是Python的实现，全栈小伙伴表示不服
- 用上面基础矩阵函数随便撸一个JS实现，4行代码搞定：

```
function PCA (data, threshold = 0.95, normfunc = util.none) {
  let arr = util.cov($M.mat.transpose(data))// 求协方差矩阵
  let qMatrx = SVD(arr) // 奇异值分解
  let mainFactorLen = findMainFactor(qMatrx.q, threshold) // 自动发现最佳主因素，默认损失率<=5%对应默认95%
  let transData = $M.mat.mul(// 矩阵乘法，计算映射降维后的数据
    util.meanStandard(normfunc(data)).meanMat, // 数据中心化
    qMatrx.u.map(x => x.slice(0, mainFactorLen)) // 奇异值分解中的左奇异矩阵
  )
  return {
    mat: transData,
    mainFactorLen
  }
}
```

特征值（奇异值）

```
let r = PCA(dataIris).q //计算鸢尾花数据集的奇异值
/*
[
  1.0562101920800278,
  0.06056089290687881,
  0.019630977023538623,
  0.005920756781500258
]
*/
```

- 可以看出来 前2项 占到总体的97.7%
- 所以可以通过用2维，代替原来的4维

实例比对

- 使用鸢尾花数据集：
- 
- 鸢尾花数据集最初由Edgar Anderson 测量得到，而后在著名的统计学家和生物学家R.A Fisher于1936年发表的文章「The use of multiple measurements in taxonomic problems」中被使用
- 鸢尾花数据集共收集了三类鸢尾花，即Setosa鸢尾花、Versicolour鸢尾花和Virginica鸢尾花，每一类鸢尾花收集了50条样本记录，共计150条😄，组成150*4的矩阵
- 每条记录都有 **4 项特征**：花萼长度、花萼宽度、花瓣长度、花瓣宽度
- 在统计学习和机器学习领域都经常被用作示例

> 简单的说我们要对鸢尾花的4维特征数据进行降维

- 先上Python，科学库已经内置鸢尾花数据集，运行10万次

```python
from sklearn.datasets import load_iris
from sklearn.decomposition import PCA  # 加载PCA算法包
import datetime

t1 = datetime.datetime.now()
data = load_iris()
y = data.target
x = data.data
for i in range(0, 100000):
    pca = PCA(n_components=2)  # 加载PCA算法，设置降维后主成分数目为2
    reduced_x = pca.fit_transform(x)  # 对样本进行降维
t2 = datetime.datetime.now()
print(reduced_x, '\n耗时: ', (t2-t1).seconds)
```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL

```
 [ 2.84167278  0.37526917]
 [ 3.23067366  1.37416509]
 [ 2.15943764 -0.21727758]
 [ 1.44416124 -0.14341341]
 [ 1.78129481 -0.49990168]
 [ 3.07649993  0.68808568]
 [ 2.14424331  0.1400642 ]
 [ 1.90509815  0.04930053]
 [ 1.16932634 -0.16499026]
 [ 2.10761114  0.37228787]
 [ 2.31415471  0.18365128]
 [ 1.9222678   0.40920347]
 [ 1.41523588 -0.57491635]
 [ 2.56301338  0.2778626 ]
 [ 2.41874618  0.3047982 ]
 [ 1.94410979  0.1875323 ]
 [ 1.52716661 -0.37531698]
 [ 1.76434572  0.07885885]
 [ 1.90094161  0.11662796]
 [ 1.39018886 -0.28266094]]
耗时：  18
```

- JS代码运行结果

```
const $ = require('meeko')
const PCA = $.ml.Pca
let dataIris = [ ...
]
irisTag = [ ...
]

$.benchmark(
  function pca () {
    let r = PCA(dataIris).mat
  },
  'PCA',
  100000
)

```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL

```
PS D:\project\test_mind> nodemon .\鸢尾花PCA.js
[nodemon] 2.0.4
[nodemon] to restart at any time, enter `rs`
[nodemon] watching path(s): *.*
[nodemon] watching extensions: js,mjs,json
[nodemon] starting `node .\鸢尾花PCA.js`
✓ Meeko (1.8.99) https://github.com/kongnet/meeko.git
pca                3539 ms     28 /ms 1e+5 次     ±6.36% PCA
```

> 非常意外，JS实现比Python科学库**快5倍**，反复确认，操作过程相同，先PCA降维，再映射原数据集💪

可视化

- 网上随便找了一个python鸢尾花降维后的图像，比对本次JS实现图像：
- 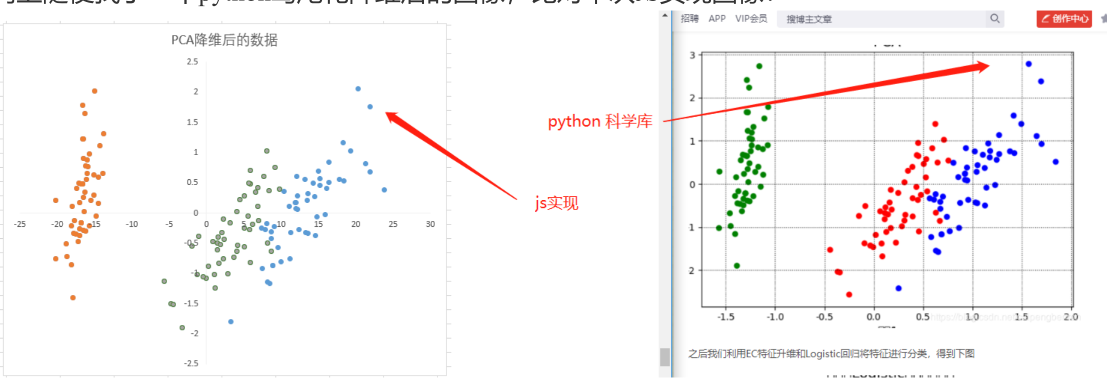

疑难点说明

- python库使用n_components=2，这里是强制将4维降维2维，但一般并不知道应该降到几维
- JS实现使用 threshold概念，即默认情况下降维压缩后的数据要保留95%的数据解释能力💪

降维的广泛应用

- 图片降维，我们熟知的jpeg格式，当然算法更复杂
- 人脸识别，朋友建议先CNN选取特征值后，再用一下PCA
- 推荐系统（找相关性），当然这个不是降维，而是用到其中的SVD奇异值分解，思路类似
- 销售指标，用户行为指标，运营指标的降维，这也是我们的重要应用场景
- 特征工程之后，就可以愉快的开始机器学习的征途了💪

书籍的推荐

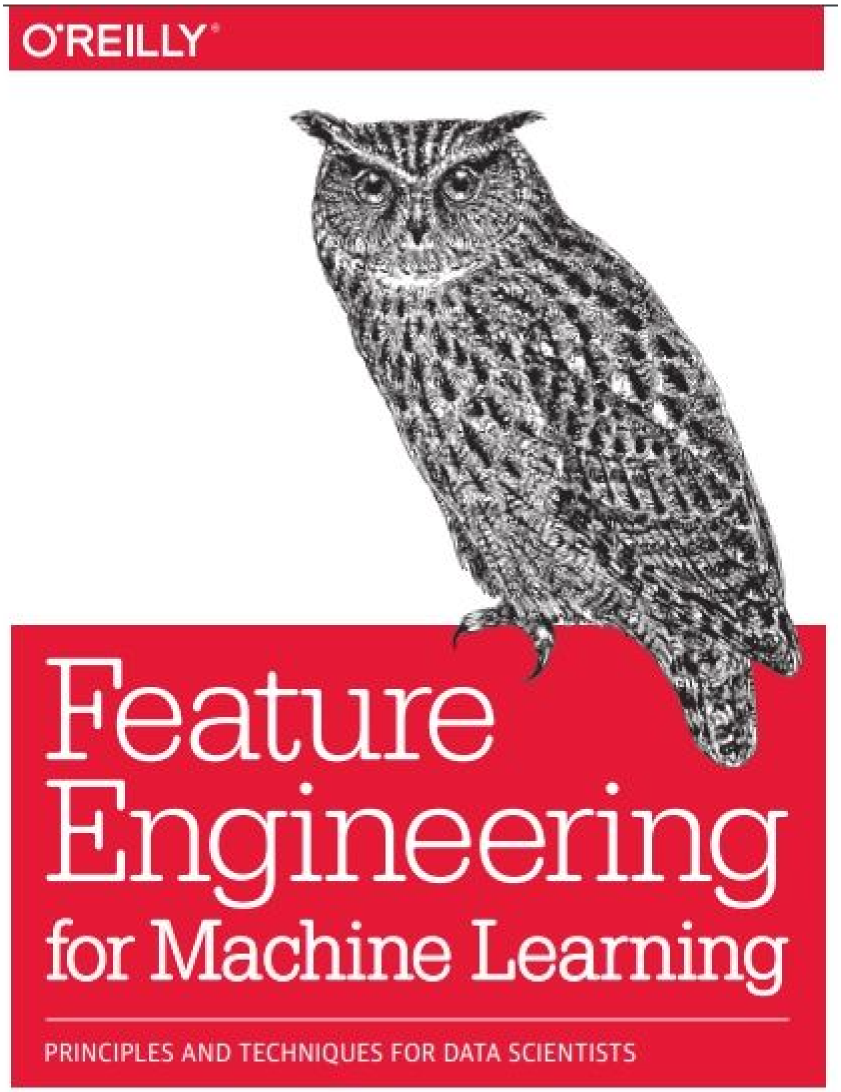

总结

通过对特征工程的简单介绍，用JS实现矩阵操作，进一步实现协方差矩阵，最终实现PCA降维分析全部算法，对数据科学中的数据预处理阶段有了初步了解。

祝大家2020提升技术，开心，发财 😄